

RELATÓRIO TÉCNICO

Agente Preditivo Especialista do Heart Disease

Machine Learning e Inteligência Artificial Generativa aplicados à predição de doença cardíaca

Alunas: Ana Carla Londero Cazarotto e Vanessa da Silva

Disciplina: Inteligência Artificial e Sistemas Inteligentes

Professor: Jacson Matte

Dataset: Heart Disease (Kaggle/UCI)

Sumário

1. Descrição do Problema
2. Exploração dos Dados
 - 2.1 Pré-processamento
 - 2.2 Mapa de Correlação
 - 2.3 Box Plot das Variáveis Numéricas
 - 2.4 Gráficos de Frequência
3. Modelagem e Comparação de Algoritmos
 - 3.1 Regressão Logística
 - 3.2 KNN (K-Nearest Neighbors)
 - 3.3 MLP (Multi-Layer Perceptron)
 - 3.4 Naive Bayes (novo nesta etapa)
 - 3.5 Matrizes de Confusão
4. Comparação de Métricas e Análise Crítica
 - 4.1 Vantagens e Limitações de Cada Algoritmo
 - 4.2 Modelo Selecionado
5. Arquitetura do Agente Inteligente
 - 5.1 Visão Geral
 - 5.2 Tratamento de Falhas
 - 5.3 Validação de Dados de Entrada
6. Conclusão

1. Descrição do Problema

Doenças cardiovasculares estão entre as principais causas de morte no mundo, e o diagnóstico precoce é fundamental para o início de tratamento adequado e redução de riscos. Este projeto tem como objetivo construir um Agente Preditivo Especialista capaz de estimar, a partir de exames clínicos de um paciente, a probabilidade de presença de doença cardíaca, e de explicar esse resultado em linguagem natural, de forma compreensível e fundamentada, através de um agente de Inteligência Artificial Generativa.

O projeto une três frentes complementares: (1) ciência de dados e aprendizado de máquina, para treinar e comparar diferentes algoritmos de classificação; (2) desenvolvimento de back-end, para servir o modelo treinado por meio de uma API e integrá-lo a um agente de IA generativa; e (3) desenvolvimento de front-end, para disponibilizar uma interface acessível ao usuário final.

A base de dados utilizada é o conjunto Heart Disease, disponível no Kaggle/UCI Machine Learning Repository, contendo 303 registros de pacientes e 13 variáveis preditoras (exames clínicos e demográficos), além da variável-alvo binária que indica presença (1) ou ausência (0) de doença cardíaca.

2. Exploração dos Dados

Antes da modelagem, foi realizada uma análise exploratória dos dados (EDA) para compreender a distribuição das variáveis, identificar possíveis inconsistências e avaliar a relação entre os atributos e a variável-alvo.

2.1 Pré-processamento

O dataset não apresentou valores nulos. Foi identificada e removida 1 linha duplicada, restando 302 registros únicos para a modelagem. A variável-alvo apresenta distribuição relativamente balanceada (165 casos positivos e 138 negativos, aproximadamente 54%/46%), o que dispensa técnicas de balanceamento de classes.

Os dados foram divididos em 80% para treino e 20% para teste, com estratificação pela variável-alvo para preservar a proporção de classes em ambos os conjuntos. Em seguida, todas as variáveis foram normalizadas com MinMaxScaler (intervalo [0, 1]), etapa necessária pois atributos como colesterol (mg/dl) e pressão arterial (mmHg) possuem escalas muito maiores que variáveis binárias (0/1), o que distorceria o cálculo de distância no KNN e a convergência do MLP.

2.2 Mapa de Correlação

O mapa de correlação (Figura 1) permite identificar quais variáveis possuem maior associação linear entre si e com a variável-alvo. Variáveis como 'cp' (tipo de dor no peito), 'thalach' (frequência cardíaca máxima) e 'exang' (angina induzida por exercício) apresentam as correlações mais relevantes com o diagnóstico.




Figura 1 — Mapa de correlação entre as variáveis do dataset.

2.3 Box Plot das Variáveis Numéricas

O box plot (Figura 2) evidencia a distribuição, dispersão e presença de outliers nas principais variáveis numéricas contínuas do dataset: idade, pressão arterial em repouso, colesterol, frequência cardíaca máxima e a depressão do segmento ST (oldpeak). Observam-se outliers pontuais em colesterol e pressão arterial, compatíveis com a variabilidade clínica esperada nesse tipo de exame.




Figura 2 — Box plot das variáveis numéricas.

2.4 Gráficos de Frequência

Os histogramas por classe (Figura 3) mostram como cada variável numérica se distribui entre pacientes com e sem doença cardíaca, e o gráfico de contagem final apresenta a frequência da variável-alvo, confirmando o balanceamento das classes.

Gráficos de Frequência — Heart Disease Dataset




Figura 3 — Distribuição das variáveis numéricas por classe e frequência da variável-alvo.

3. Modelagem e Comparação de Algoritmos

Foram treinados e comparados quatro algoritmos de classificação supervisionada. Para os algoritmos com hiperparâmetros relevantes (KNN e MLP), foi utilizado GridSearchCV com validação cruzada (5 folds) para a escolha da melhor configuração.

3.1 Regressão Logística

Observação metodológica: o enunciado do trabalho menciona 'Regressão Linear Múltipla'. Como o problema tratado é de classificação binária (presença/ausência de doença), e não de previsão de um valor contínuo, o algoritmo linear adequado é a Regressão Logística — que aplica a função sigmoide sobre a combinação linear das variáveis para estimar a probabilidade da classe positiva. A Regressão Linear pura não é adequada a problemas de classificação, razão pela qual foi mantida a Regressão Logística, já utilizada no trabalho anterior da equipe.

Foram testados diferentes valores do hiperparâmetro de regularização C (0,01 a 100), e o modelo com C=1 apresentou o melhor desempenho no conjunto de teste.

3.2 KNN (K-Nearest Neighbors)

O KNN classifica uma nova amostra com base na classe majoritária entre seus K vizinhos mais próximos no espaço de atributos normalizados. A busca em grade (K ímpar, de 1 a 21) identificou K=9 como a melhor configuração, segundo a acurácia média obtida por validação cruzada.




Figura 4 — Acurácia média (validação cruzada) por valor de K.

3.3 MLP (Multi-Layer Perceptron)

O MLP é uma rede neural artificial composta por uma ou mais camadas ocultas de neurônios, capaz de capturar relações não-lineares complexas entre as variáveis. Foram testadas diferentes arquiteturas (uma a três camadas ocultas, com 30 a 100 neurônios) e funções de ativação (ReLU e tangente hiperbólica). A configuração com uma única camada oculta de 50 neurônios e ativação ReLU apresentou o melhor desempenho médio em validação cruzada.

3.4 Naive Bayes (novo nesta etapa)

O Naive Bayes é um classificador probabilístico fundamentado no Teorema de Bayes, que assume independência condicional entre as variáveis preditoras dado o valor da classe — uma

simplificação 'ingênuas', mas que na prática costuma funcionar bem mesmo quando essa independência não é estritamente verdadeira. Como as variáveis do dataset são predominantemente numéricas contínuas, foi utilizada a variante Gaussiana (GaussianNB), que modela a distribuição de cada atributo, dentro de cada classe, como uma distribuição normal.

O Naive Bayes não exige busca de hiperparâmetros, sendo extremamente rápido para treinar e prever — uma vantagem relevante considerando o tamanho reduzido do dataset (302 registros).

3.5 Matrizes de Confusão




Figura 5 — Matriz de confusão: Regressão Logística.




Figura 6 — Matriz de confusão: KNN (K=9).




Figura 7 — Matriz de confusão: MLP.




Figura 8 — Matriz de confusão: Naive Bayes.

4. Comparação de Métricas e Análise Crítica

As métricas de avaliação foram calculadas sobre o conjunto de teste (20% dos dados, nunca utilizado no treinamento). A Tabela 1 resume os resultados:

Modelo	Acurácia	Sensibilidade	Especificidade	Precisão	F1-Score
Regressão Logística (C=1)	78,69%	90,91%	64,29%	75,00%	0,8219
KNN (K=9)	77,05%	84,85%	67,86%	75,68%	0,8000
MLP (50,) relu	80,33%	87,88%	71,43%	78,38%	0,8286
Naive Bayes (Gaussian)	81,97%	90,91%	71,43%	78,95%	0,8451

Tabela 1 — Comparação de métricas entre os quatro algoritmos. Naive Bayes (destacado) obteve a maior acurácia.




Figura 9 — Comparação visual das métricas entre os quatro algoritmos.

4.1 Vantagens e Limitações de Cada Algoritmo

- Regressão Logística — Vantagens: simples, rápida, altamente interpretável (coeficientes indicam a direção e força da influência de cada variável). Limitações: assume uma relação linear entre as variáveis e o log-odds da classe, podendo não capturar padrões mais complexos.
- KNN — Vantagens: não-paramétrico, captura padrões não-lineares localmente, simples de entender. Limitações: sensível à escala dos dados e a outliers; custo computacional cresce com o tamanho da base; exige escolher cuidadosamente o valor de K.
- MLP — Vantagens: capaz de aprender relações não-lineares complexas entre as variáveis. Limitações: funciona como uma 'caixa-preta' (baixa interpretabilidade), exige mais dados e ajuste de hiperparâmetros para evitar overfitting, e é mais sensível a variações aleatórias de inicialização em bases pequenas como esta.
- Naive Bayes — Vantagens: extremamente rápido para treinar e prever, robusto mesmo com poucos dados, fornece probabilidades bem calibradas na maioria dos casos. Limitações: assume independência condicional entre as variáveis, premissa raramente

verdadeira na prática (por exemplo, colesterol e idade tendem a ser correlacionados), o que pode comprometer a precisão em datasets com forte dependência entre atributos.

4.2 Modelo Selecionado

Considerando a acurácia no conjunto de teste como critério principal de seleção, o algoritmo Naive Bayes (Gaussian) apresentou o melhor desempenho geral (81,97% de acurácia, 90,91% de sensibilidade e F1-Score de 0,8451), sendo o modelo exportado e integrado ao backend da aplicação. Vale destacar que a sensibilidade — capacidade de identificar corretamente os pacientes que de fato possuem a doença — é especialmente relevante neste contexto clínico, pois um falso negativo (não detectar a doença) tende a ser mais custoso que um falso positivo.

5. Arquitetura do Agente Inteligente

A solução final foi estruturada em três camadas que se comunicam via API REST, conforme descrito a seguir.

5.1 Visão Geral

1) O notebook de Machine Learning treina e compara os quatro algoritmos e exporta automaticamente o modelo de melhor desempenho (modelo_final.pkl), o normalizador (scaler.pkl) e os metadados de avaliação (metadados.json).

2) O backend, desenvolvido em FastAPI, carrega esses artefatos na inicialização e expõe o endpoint POST /predict, que recebe os dados de um paciente, aplica a normalização, executa a predição com o modelo Naive Bayes e monta um prompt estruturado com o resultado, as probabilidades e as métricas reais do modelo.

3) Esse prompt é enviado à API do Gemini (modelo gemini-2.0-flash), configurada com um System Prompt que instrui o agente a: (i) deixar claro que se trata de uma estimativa estatística e não de um diagnóstico médico; (ii) utilizar exclusivamente os dados fornecidos no prompt, sem inventar exames, causas ou recomendações de tratamento; (iii) mencionar o nível de confiabilidade do modelo com base nas métricas reais informadas; e (iv) responder em português, de forma clara e em no máximo dois parágrafos. A temperatura da geração foi definida em 0,3 para priorizar respostas factuais e reduzir a variabilidade criativa.

4) O frontend, desenvolvido em Streamlit, oferece um formulário para entrada dos dados clínicos do paciente, envia a requisição ao backend e exibe tanto o resultado bruto do modelo (classe prevista e probabilidades) quanto a explicação gerada pelo agente de IA.

5.2 Tratamento de Falhas

Caso a API do Gemini esteja indisponível ou a chave não esteja configurada, o backend continua retornando normalmente o resultado bruto da predição, exibindo uma mensagem informativa no lugar da explicação textual, garantindo que a funcionalidade essencial (predição) não dependa de um serviço externo para funcionar.

5.3 Validação de Dados de Entrada

Todos os campos recebidos pela API são validados via Pydantic, com limites mínimos e máximos definidos a partir do dicionário de variáveis do dataset (Tabela 2), rejeitando automaticamente entradas fora dos intervalos clinicamente plausíveis.

Variável	Descrição	Valores
age	Idade do paciente	anos
sex	Sexo	1 = masculino, 0 = feminino
cp	Tipo de dor no peito	0 a 3
trestbps	Pressão arterial em repouso	mmHg
chol	Colesterol sérico	mg/dl

Variável	Descrição	Valores
fbs	Glicemia de jejum > 120 mg/dl	1 = sim, 0 = não
restecg	Resultado do ECG em repouso	0 a 2
thalach	Frequência cardíaca máxima atingida	bpm
exang	Angina induzida por exercício	1 = sim, 0 = não
oldpeak	Depressão do segmento ST	valor numérico
slope	Inclinação do segmento ST no pico do exercício	0 a 2
ca	Número de vasos principais (fluoroscopia)	0 a 4
thal	Talassemia	0 a 3
target	Diagnóstico (variável alvo)	1 = doença, 0 = ausência

Tabela 2 — Dicionário de variáveis do dataset Heart Disease.

6. Conclusão

O projeto demonstrou, de ponta a ponta, a construção de um agente preditivo especialista: desde a exploração e modelagem dos dados até a entrega de uma interface acessível ao usuário final, passando pela integração entre um modelo de Machine Learning clássico e um agente de Inteligência Artificial Generativa responsável por 'traduzir' o resultado matemático em uma explicação compreensível. Entre os quatro algoritmos testados, o Naive Bayes obteve o melhor equilíbrio entre acurácia, sensibilidade e simplicidade computacional, sendo o modelo escolhido para produção. A arquitetura modular (notebook → backend → frontend) permite que o modelo seja retreinado e reexportado a qualquer momento, sem necessidade de alterar o backend ou o frontend.

Por fim, ressalta-se que esta ferramenta possui finalidade exclusivamente acadêmica e educacional, não devendo ser utilizada como substituto de avaliação, diagnóstico ou tratamento médico profissional.